

基于 RoBERTa 与多维独立分类头的文本 MBTI 人格预测与可解释性分析

吴俊达 王琦锋 陈明阳 刘毅恒

计算机科学与技术学院

2026 年 6 月 10 日

① 项目背景

② 数据集

③ 模型设计

④ 实验结果

⑤ 总结

项目简介

项目简称: **MBTI Personality Prediction**

目标: 根据用户发布的英文论坛文本, 预测其 MBTI 性格类型。

任务定义

输入:

用户历史帖子文本

输出:

MBTI 四个维度 (E/I, S/N, T/F, J/P)

最终组合得到 16 种 MBTI 类型

数据规模: 106,067 条样本

模型: RoBERTa-base + Multi-Task Classification

最终 Exact Match: 86.0%

数据集介绍

数据来源:

PersonalityCafe 论坛用户匿名帖子

Kaggle 公开数据集

样本数	106,067
MBTI 类别	16 类
平均文本长度	3255 字符
最大长度	13180 字符

特点:

长文本任务

类别严重不均衡

论坛语言风格明显

分类策略

选中：

$(E/I, S/N, T/F, J/P)$

四个二分类。

这样设计的原因

- a 每个分类器都能利用全部 106k 样本
- b 可解释性更强
- c 可以针对单个维度处理类别不平衡
- d 训练稳定性优于 16 分类

数据预处理

主要步骤:

- a URL 清理
- b HTML 标签清理
- c @Mention 清理
- d 帖子分隔符清理
- e 空白字符规范化

标签转换:

$$INTP \rightarrow (EI, SN, TF, JP) = (1, 1, 1, 1)$$

数据划分:

Train: 84,853

Test: 21,214

Stratified Split

模型整体架构



最终组合得到 16 种 MBTI 类型。

RoBERTa 编码器

采用：

FacebookAI/roberta-base

12 层 Transformer

768 维隐藏层

125M 参数

设计选择：

CLS Pooling

max_length=512

全参数微调 (Fine-tuning)

原因：

英文预训练效果成熟

长文本适配良好

实验验证优于 Mean Pooling

多任务分类头设计

768

↓

64

↓

1

每个维度一个独立分类器：

EI

SN

TF

JP

为什么不共享隐藏层？

四个维度关注的语言特征不同：

EI：社交表达

SN：抽象程度

TF：逻辑与情感

JP：计划性表达

训练配置

Optimizer	AdamW
Encoder LR	2.84e-5
Classifier LR	1e-4
Batch Size	32
Max Length	512
FP16	True
Epochs	7

额外策略:

Cosine Learning Rate

Warmup

Gradient Clipping

Mixed Precision Training

类别不平衡处理

问题:

S 类仅占 8.7%

I 类占 76.1%

解决方案:

BCEWithLogitsLoss

pos_weight

提高 SN 维度损失权重

总损失:

$$L = 0.25L_{EI} + 0.35L_{SN} + 0.20L_{TF} + 0.20L_{JP}$$

超参数搜索

采用：

Optuna

Random Search

两阶段搜索：

a 离散参数

Pooling

Head Hidden Size

b 连续参数

Learning Rate

Dropout

Weight Decay

Warmup

总计 18 次 Trial。

超参数搜索结果

阶段一最佳:

CLS Pooling

Hidden Size=512

阶段二最佳:

Encoder LR = $2.84e-5$

Warmup = 0.027

重要发现

子集搜索得到的最优参数不一定直接适用于全量训练。

因此最终采用:

保留离散参数最优解

连续参数适当回退

最终实验结果

指标	数值
Exact Match	86.0%
Mean Accuracy	95.1%
Mean F1	93.7%
Mean AUC	98.0%
Macro MCC	0.854


最佳维度:

SN F1 = 0.989

最困难维度:





EI F1 = 0.885

ROC 曲线分析



四个维度 AUC 均接近 1
模型具有较强区分能力
TF 维度表现最好

混淆矩阵分析




EI 和 JP 错误相对较多

SN 维度分类几乎完全正确

错误主要来自相邻人格倾向

模型输出分析


MBTI 4-Dimension Radar



综合展示四个维度性能。

模型输出分析

Confidence Distribution — Correct vs Wrong



模型预测置信度分布。

与 Baseline 比较

指标	Baseline	最终模型
Overall Acc	80.6%	86.0%
Mean Acc	93.2%	95.1%
Mean F1	91.3%	93.7%

提升:

Overall Accuracy +5.4pp

Mean F1 +2.4pp

说明:

超参数搜索有效

CLS Pooling 贡献明显

长文本输入十分重要

开发过程中的关键问题

问题	解决方案
FP16 下 BCELoss 崩溃	Loss 改为 FP32 计算
学习率错误	检查配置文件数值类型
搜索结果失效	参数回退策略
Batch 过大训练慢	128 降至 32

总结与未来工作

项目成果

完成 106k 样本 MBTI 预测系统

实现 RoBERTa 多任务分类架构

完成超参数自动搜索

Exact Match 达到 86.0%

未来方向

RoBERTa-large

Focal Loss

更严格的用户级划分

更强的可解释性分析模块

Thanks!